

28 janvier 2021

## Table des matières

1	Introduction		3
2	Automatisation du déploiement de Kubernetes sur EC2 de AWS		3
	2.1	KeyPairToFile()	4
	2.2	CreateSecurityGroup()	4
	2.3	createInstances()	4
	2.4	getPublicIpOfRunningInstances()	4
	2.5	${\sf execute\_command\_with\_ssh()}  .  .  .  .  .  .  .  .  .  $	5
	2.6	Implantation finale	5
	2.7	Difficultes	5
3	Automatisation du déploiement de WordCount avec Spark dans le cluster Kubernetes		6
4	Difficultés		7
5	Dép	loiement d'un outil de monitoring : Kube-Opex-Analytics	7
6	Participation de chaque membre du groupe :		9

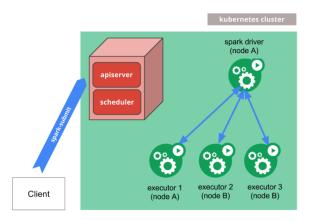
#### 1 Introduction

Ce projet avait pour but d'automatiser le déploiement de Spark sur Kubernetes, sur un cluster de VM AWS, et d'utiliser un outil de monitoring sur Kubernetes.

Pour cela, nous nous sommes dans un premier temps occupés d'automatiser le déploiement d'un Kubernetes sur les machines EC2 de AWS.

Nous nous sommes ensuite intéressés à l'automatisation du déploiement d'une application de Spark dans ce cluster Kubernetes.

Et nous avons finalement travaillé sur le déploiement d'un outil de monitoring afin d'évaluer l'utilisation du cluster Kubernetes.

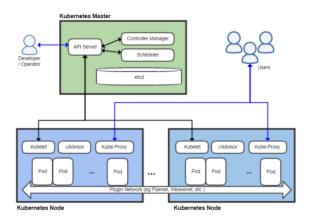


## 2 Automatisation du déploiement de Kubernetes sur EC2 de AWS

Nous avons utilisé le SDK de python Boto3 pour le développement des différentes parties. Pour réaliser le Cluster Kubernetes les 5 fonctions suivantes ont été implantées :



#### Architecture du Kubernetes :



### 2.1 KeyPairToFile()

Le but de cette fonction est de créer une clé dans AWS et de la stocker localement dans un fichier.

### 2.2 CreateSecurityGroup()

Cette fonction crée un groupe de sécurite dans AWS avec la permission des règles entrantes sur ports 80(HTTP), 22(SSH), 6443(Pour la commande kubeadm join) et 5483(Pour Kube-Opex-Analytics).

### 2.3 createInstances()

Cette fonction crée des instances sur AWS avec la distribution la distribution qu'on choisi. Nous avons déployé des instances de type linyx (gratuite), de type t3.small qui remplit les prérequis du déploiment d'un Cluster Kubernetes. Liée par la clé et le groupe de sécurité crées précédemment.

### 2.4 getPublicIpOfRunningInstances()

Cette fonction va retourner les adresses IP des instances en cours d'execution sur AWS.

#### 2.5 execute\_command\_with\_ssh()

Cette fonction a comme paramètre le nom de l'utilisateur, l'adresse IP de l'instance, ainsi que la commande qu'on veut exécuter sur l'instance. Elle permet de se connecter à nos instances pour exécuter la commande donnée dans les paramètres. elle retourne la derniere ligne du terminal de l'instance à laquelle on est connecté à travers SSH. On verra son utilité dans la partie Difficultés

#### 2.6 Implantation finale

On crée la clé d'authentification qu'on stocke dans un fichier, le groupe de sécurité puis notre master et slaves. Ensuite, en envoie les fichiers de configurations master.conf et slave.conf dans l'instance du master et slaves respectivement afin d'y exécuter notre configuration shell.

#### 2.7 Difficultes

1- Il fallait attendre la création des instances EC2 du master et du slave avant de continuer l'exécution du code. Pour remédier à cela, nous avons utilisé la fonction sleep de time en arrêtant l'exécution du code pendant 90 secondes. Cependant ce n'est pas la méthode la plus optimale en terme de temps d'exécution. On pouvait par exemple ajouter ces lignes de code suivant au lieu du sleep. On a opté pour le time.sleep parce que le code est plus lisible et permet de resoudre le même problème en une ligne.

```
ec2 = boto3.resource('ec2', region_name='us-east-2')
instance = ec2.Instance(id=instance_id)
instance.wait_until_running()
```

- 2- Pour réaliser les fonctions SSH et SCP il fallait modifier les droits du fichier contenant la clé d'authentification pour permettre a l'utilisateur root seulement d'accéder à la clé à travers la commande chmod 400 .
- 3- Dans la partie de execute\_command\_with\_ssh() , on a vu que notre fonction ssh retournait un string. Ce string s'agit de la join command (kubeadm join) qu'on va récuperer dans une variable puis on modifiera la derniere ligne de notre fichier de configuration du slave pour y ajouter cette commande pour que le slave puisse rejoindre le master.
- 4- Cette difficulté découle de la difficulté précédente, en effet qu'on on enregistre la join commande on enregistre aussi les 'retailing spaces', on doit donc impérativement les retirer pour que notre commande kubeadm join puisse marcher.

# 3 Automatisation du déploiement de WordCount avec Spark dans le cluster Kubernetes

Pour réaliser cette partie, il fallait importer le fichier de SPARK, HADOOP ET JAVA en définissant les variables d'environnement de JAVA\_HOME, SPARKHOME ET HADOOPHOME. Puis on compile word-count pour avoir un jar.

```
ubuntu@master:~$ ls
WordCount.java master_conf.sh spark_master.sh
hadoop-2.7.1 spark-3.0.1-bin-hadoop2.7
hadoop-2.7.1.tar.gz spark-3.0.1-bin-hadoop2.7.tgz
```

On veille bien a mettre le filesample.txt dans le répertoire data et le wc.jar dans les jars. Puis on buildait une docker image a partir de notre repertoire bin et on définissait bien le service account et le clusterrolebinding. Une fois toutes ces étapes réalisées on exécute le spark submit en lui donnant l'adresse du cluster avec le port 6443, le répertoire de l'image docker ainsi que son tag.

#### 4 Difficultés

1) Malgrè que toutes ces étapes aient été suivies, le pod exécutant le word count reste dans l'état Running et n'évolue pas a l'état attendu : Completed. L'erreur affichée est liee a une impossibilité d'instancier le SparkContext.

21/01/28 05:51:03 ERROR SparkContext: Error initializing SparkContext. org.apache.spark.SparkException: External scheduler cannot be instantiated

- 2) Au debut on a fait face a une erreur concernant le chemin local au jar, on a pu le reperer grace aux deux commandes kubectl get pods qui listaient les pods sur la VM, puis kubectl logs IdPod.
- 3) Les fichiers .jar et samples.txt etaient mis en dehors du docker spark cela donnait l'etat Pending aux pods , et des qu'on les a mis respectivement dans le dossier /jars et /data ils se sont mis dans l'etat running.
- 4] Des erreurs liees au pare-feu du trafic entrant nous a pousse a laisser rentrer tout le trafic.

# 5 Déploiement d'un outil de monitoring : Kube-Opex-Analytics

Nous devions dans cette partie, déployer un outil de monitoring sur le cluster Kubernetes : Kube-Opex-Analytics.

Bref, Kube-Opex-Analytics est un outil destiné à aider les organisations à suivre les ressources consommées par leurs clusters Kubernetes afin d'éviter les surpaiements. À cette fin, il génère des rapports d'utilisation à court, moyen et long terme montrant des informations pertinentes sur la quantité de ressources consommée par chaque projet au fil du temps. L'objectif final étant de faciliter les décisions d'allocation des coûts et de planification de la capacité grâce à des analyses factuelles.

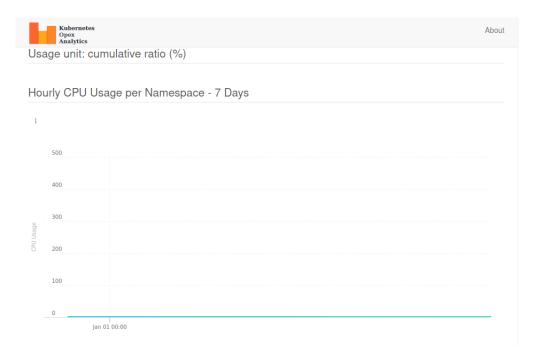
Pour automatiser le déploiement de cet outil, On a créé un script shell contenant deux commandes majeures. La premiere sert a avoir un accès en lecture seule aux API Kubernetes suivantes en utilisant Kubernetes Metrics Server :

- /api/v1
- /apis/metrics.k8s.io/v1beta1

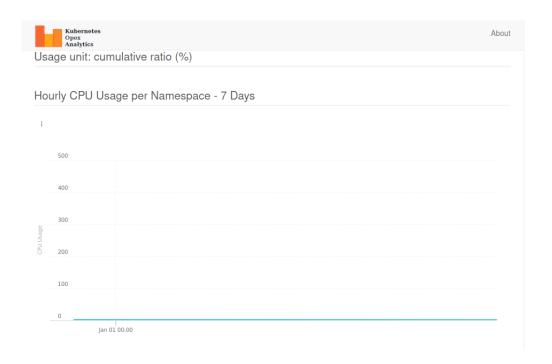
La deuxieme commande installe une instance de kube-opex-analytics dejà lancée par une image Docker.

Afin de visualiser les résultats. On accéde à l'interface graphique de l'outil via le port 5483.

Avant de lancer l'application WordCount sur spark dans le cluster Kubernetes. On voit que la consommation des ressources est nulle.



Aprés l'exécution de l'application WordCount :



Difficultés rencontrées : Pour cette section, On n'a pas pu acceder a l'interface graphique due a d'interdiction par le protocole HTTPS. Mais, On a pu résoudre ce probleme en ajoutant une section dans la creation du security group pour tout type du traffic.

### 6 Participation de chaque membre du groupe :

Pour l'automatisation du Kubernetes : Tout le monde a participé dessus. Younes OSMAN et Mina ALLA : Déploiement du Spark et l'application WordCount. Aymen BEN ABDELLAH et Gwendhal Borremans : Déploiement du Kube-Opex-Analytics.